Домашнее задание № 2: Разработка многослойного персептрона на основе обратного распространения ошибки FFNN

1 октября 2024 г.

Сергей Виленский, ИУ9-72Б

Цель работы

Изучение многослойного персептрона, исследование его работы на основе использования различных методов оптимизации и целевых функций.

Постановка задачи

- 1. Реализовать на языке высокого уровня многослойный персептрон и проверить его работоспособность на примере данных, выбранных из MNIST dataset.
- 2. Исследовать работу персептрона на основе использования различных целевых функций. (среднеквадратичная ошибка, перекрестная энтропия, дивергенция Кульбака-Лейблера).
- 3. Исследовать работу многослойного персептрона с использованием одного метода оптимизации, градиентного спуска.
- 4. Провести исследование эффективности работы многослойного персептрона при изменении гиперпараметров (количества нейронов).
- 5. Подготовить отчет с распечаткой текста программы, графиками результатов исследования и анализом результатов.

Реализация

import copy
import numpy as np
import matplotlib.pyplot as plt
from dataclasses import dataclass
from typing import Callable, List

```
@dataclass
class Function:
    func: Callable[[float], float]
    derivative: Callable[[float], float]
class Perceptron:
   def __init__(
        self,
        input_layer_size: int,
        hidden_layers_sizes: tuple,
        output_layer_size: int,
        init_weights_function: Callable[[tuple], tuple],
        activation_functions: tuple, # Кортеж функций активации для каждого скрытого слоя
        output_activation_function: Function,
        loss_function: Function,
        epochs: int,
        learning_rate: float = 0.01,
    ):
        self.input_layer_size = input_layer_size
        self.hidden_layers_sizes = hidden_layers_sizes # Кортеж с размерами скрытых слоев
        self.output_layer_size = output_layer_size
        self.activation_functions = activation_functions # Кортеж с функциями активации
        self.output_activation_function = output_activation_function
        self.loss_function = loss_function
        self.epochs = epochs
        self.learning_rate = learning_rate
        # Инициализация весов и смещений (biases)
        self.weights = []
        self.biases = []
        # Веса между входным слоем и первым скрытым слоем
        self.weights.append(init_weights_function((hidden_layers_sizes[0], input_layer_size)
        self.biases.append(np.random.randn(hidden_layers_sizes[0]))
        # Веса между скрытыми слоями
        for i in range(1, len(hidden_layers_sizes)):
            self.weights.append(init_weights_function((hidden_layers_sizes[i], hidden_layers
            self.biases.append(np.random.randn(hidden_layers_sizes[i]))
        # Веса между последним скрытым слоем и выходным слоем
        self.weights.append(init_weights_function((output_layer_size, hidden_layers_sizes[-1
        self.biases.append(np.random.randn(output_layer_size))
   def predict(self, X: np.ndarray, get_probabilities: bool = False) -> int | list:
```

current_input = X

```
# Прямой проход через скрытые слои с индивидуальными функциями активации
    for i in range(len(self.hidden_layers_sizes)):
        z = np.dot(self.weights[i], current_input) + self.biases[i]
        current_input = self.activation_functions[i].func(z) # Применение индивидуально
   # Прямой проход через выходной слой
    z = np.dot(self.weights[-1], current_input) + self.biases[-1]
    output = self.output_activation_function.func(z)
    return output if get_probabilities else int(np.argmax(output))
def fit(self, X: np.ndarray, y: np.ndarray) -> None:
    # Преобразуем метки у в формат "one-hot encoding"
    y_one_hot = np.zeros((len(y), self.output_layer_size))
    for i, label in enumerate(y):
        y_one_hot[i, label] = 1
    for epoch in range(self.epochs):
        for i in range(len(X)):
            # Прямой проход (вычисление предсказания)
            outputs = [X[i]] # Сохраняем выходы каждого слоя
            current_input = np.array(X[i])
            # Прямой проход через скрытые слои с индивидуальными функциями активации
            for j in range(len(self.hidden_layers_sizes)):
                z = np.dot(self.weights[j], current_input) + self.biases[j]
                current_input = self.activation_functions[j].func(z)
                outputs.append(current_input)
            # Прямой проход через выходной слой
            z = np.dot(self.weights[-1], current_input) + self.biases[-1]
            output = self.output_activation_function.func(z)
            outputs.append(output)
            # Вычисление ошибки и градиента функции потерь
            loss_gradient = self.loss_function.derivative(output, y_one_hot[i])
            # Обратное распространение ошибки для выходного слоя
            # Вычисление матрицы Якобиана
            jacobian = self.output_activation_function.derivative(output)
            # Градиент по логитам (умножение матрицы Якобиана на градиент функции потерь
            delta = np.dot(jacobian, loss_gradient)
            self.weights[-1] -= self.learning_rate * np.outer(delta, outputs[-2])
```

```
self.biases[-1] -= self.learning_rate * delta
                # Обратное распространение для скрытых слоев с индивидуальными функциями акт
                for j in range(len(self.hidden_layers_sizes) - 1, -1, -1):
                    jacobian = self.activation_functions[j].derivative(outputs[j + 1])
                    delta = np.dot(jacobian, np.dot(self.weights[j + 1].T, delta))
                    self.weights[j] -= self.learning_rate * np.outer(delta, outputs[j])
                    self.biases[j] -= self.learning_rate * delta
    def evaluate(self, X: np.ndarray, y: np.ndarray) -> float:
        correct_predictions = 0
        for i in range(len(X)):
            prediction = self.predict(X[i])
            if prediction == y[i]:
                correct_predictions += 1
        # Возвращаем долю правильных предсказаний
        return correct_predictions / len(X)
    def validate(self, X_val: np.ndarray, y_val: np.ndarray) -> float:
        total\_loss = 0.0
        n = len(X_val)
        # Преобразуем метки в one-hot encoding, если это необходимо
        y_one_hot = np.zeros((len(y_val), self.output_layer_size))
        for i, label in enumerate(y_val):
            y_{one_hot[i, label] = 1}
        for i in range(n):
            # Прямой проход для получения предсказания
            prediction = self.predict(X_val[i], get_probabilities=True)
            # Вычисляем функцию потерь для текущего примера
            loss = self.loss_function.func(prediction, y_one_hot[i])
            total_loss += loss
        # Возвращаем среднее значение функции потерь
        return total_loss / n
def he_init(size):
    return np.random.randn(*size) * np.sqrt(2.0 / size[1])
def xavier_init(size):
    return np.random.randn(*size) * np.sqrt(1.0 / size[1])
```

```
k = 3
ReLU = Function(
   func=lambda x: np.where(x > 0, k * x, 0),
    derivative=lambda x: np.diag(np.where(x > 0, k, 0)),
Softmax = Function(
    func=lambda x: (lambda exp_x: exp_x / (np.sum(exp_x) + 1e-9))(np.exp(x - np.max(x))),
    derivative = lambda x: np.diagflat(x) - np.outer(x, x),
)
MSE = Function(
    func=lambda y_pred, y_true: np.mean((y_true - y_pred) ** 2),
    derivative=lambda y_pred, y_true: 2 * (y_pred - y_true) / y_true.size,
CrossEntropy = Function(
    func=lambda y_pred, y_true: -np.log(y_pred[np.argmax(y_true)] + 1e-9),
    derivative=lambda y_pred, y_true: -y_true / (y_pred + 1e-9),
KL_Divergence = CrossEntropy
from tensorflow.keras.datasets import mnist
(x_train, y_train), (x_test, y_test) = mnist.load_data()
x_{train} = x_{train.reshape(-1, 28**2) / 255}
x_{test} = x_{test.reshape(-1, 28**2) / 255}
x_train.shape, y_train.shape, x_test.shape, y_test.shape
model_default = Perceptron(
    input_layer_size=784, # 28**2
    hidden_layers_sizes=(512, 256, 128, 64),
    output_layer_size=10,
    init_weights_function=he_init,
    activation_functions=(ReLU, ReLU, ReLU, ReLU),
    output_activation_function=None,
   loss_function=None,
    epochs=1,
   learning_rate=1e-3,
)
epochs_count = 10
epoch_list = list(range(0, epochs_count + 1))
```

```
def get_accuracies(output_activation_function, loss_function):
   model = copy.deepcopy(model_default)
   model.output_activation_function = output_activation_function
    model.loss_function = loss_function
    accuracies = np.array([model.evaluate(x_test, y_test)])
    losses = np.array([model.validate(x_test, y_test)])
    print(accuracies[-1], losses[-1])
    for i in range(1, epochs_count + 1):
        model.fit(x_train, y_train)
        accuracies = np.append(accuracies, model.evaluate(x_test, y_test))
        losses = np.append(losses, model.validate(x_test, y_test))
        print(accuracies[-1], losses[-1])
    print()
    return accuracies, losses
ReLU_MSE = get_accuracies(ReLU, MSE)
ReLU_CrEntr = get_accuracies(ReLU, CrossEntropy)
ReLU_KLD = ReLU_CrEntr # get_accuracies(ReLU, KL_Divergence)
Softmax_MSE = get_accuracies(Softmax, MSE)
Softmax_CrEntr = get_accuracies(Softmax, CrossEntropy)
Softmax_KLD = Softmax_CrEntr # get_accuracies(Softmax, KL_Divergence)
plt.plot(epoch_list, ReLU_MSE[0], label="ReLU_MSE")
plt.plot(epoch_list, ReLU_CrEntr[0], label="ReLU_CrEntr")
# plt.plot(epoch_list, ReLU_KLD[0], label="ReLU_KLD")
plt.plot(epoch_list, Softmax_MSE[0], label="Softmax_MSE")
plt.plot(epoch_list, Softmax_CrEntr[0], label="Softmax_CrEntr")
# plt.plot(epoch_list, Softmax_KLD[0], label="Softmax_KLD")
plt.title("Зависимость точности от количества эпох")
plt.xlabel("Количество эпох")
plt.ylabel("Точность")
plt.grid(True)
plt.legend()
plt.show()
plt.plot(epoch_list, ReLU_MSE[1] / ReLU_MSE[1][0], label="ReLU_MSE")
plt.plot(epoch_list, ReLU_CrEntr[1] / ReLU_CrEntr[1][0], label="ReLU_CrEntr")
# plt.plot(epoch_list, ReLU_KLD[1] / ReLU_KLD[1][0], label="ReLU_KLD")
\verb|plt.plot(epoch_list, Softmax_MSE[1]| / Softmax_MSE[1][0], label="Softmax_MSE")| \\
plt.plot(epoch_list, Softmax_CrEntr[1] / Softmax_CrEntr[1][0], label="Softmax_CrEntr")
```

```
plt.title("Зависимость значения функции потерь от количества эпох")
plt.xlabel("Количество эпох")
plt.ylabel("Значение функции потерь")
plt.grid(True)
plt.legend()
plt.show()
```

Результаты экспериментов

Размеры скрытых слоев	Константа обучения	Зависимость точности от эпох	Зависимость
	обучения	10чности от эпох	потерь от эпох
(512, 256, 128, 64)	1e-3	Statements to resource of a source real area. 1112 1112 1112 1112 1112 1112 1112 1	Same content, to manifold of groups of the content to broad the content
		3886/000/c to Towork of Administration 3700/c 6.132 6.131 6.	SIBICORECTS INVESTIGATE TOTAL OF CONTROLLED AND CONTROL
(256, 128, 64, 32)	1e-3	0.099	-0.73 - RELL_CETER
		State Stat	Зависинисть эконения функции готорь, от компества эток при
(256, 256, 256, 256)	1e-3	0 00/0 1 4 4 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1	0 2 4 0 0 20 KONHECTED SYDIX
		30000000000000000000000000000000000000	Зависиотся, замений функции поторь, от количества этом. 1.0 — верхня — не при
(256, 256, 256, 256)	1e-6	0 2 4 0 8 30 Marenectto 2018	0.0 2 4 0 0 320 Nistanectra stee

Выводы

В данной задаче функции потерь перекрестная энтропия и дивергенция Кульбака-Лейблера эквивалентны за счет специфики задачи классификации и формата ожидаемых данных one-hot. В ходе выполнения домашнего задания

было выявлено, что на выходном слое в данной задаче эффективнее всего использовать функцию активации Softmax. Также было выявлено, что в данном случае эффективнее оказалась структура персептрона, содержащая скрытые слои одинакового размеры, и быстрее всего сходится функция потерь при использовании в качестве функции потерь функцию кросс-энтропии.