# Домашнее задание № 4: Исследование влияния гиперпараметров на работу нейронной сети

5 ноября 2024 г.

Сергей Виленский, ИУ9-72Б

### Цель работы

В работе предлагается сравнить современные методы оптимизации, а также изучить устройство генетического алгоритма на примере оптимизации гипермараметров.

#### Постановка задачи

- 1. Сравнительный анализ современных методов оптимизации (SGD, NAG, Adagrad, ADAM) на примере многослойного персептрона.
- 2. Использование генетического алгоритма для оптимизации гиперпараметров (число слоев и число нейронов) многослойного персептрона.

#### Реализация

```
import copy
import numpy as np
import matplotlib.pyplot as plt
from dataclasses import dataclass
from typing import Callable, List

@dataclass
class Function:
    func: Callable[[float], float]
    derivative: Callable[[float], float]

class Optimizer:
    def __init__(self, model):
```

```
self.model = model
    def fit(self, X, y):
        return None
class GD(Optimizer):
    def fit(self, X, y):
        for i in range(X.shape[0]):
            # Прямой проход (вычисление предсказания)
            outputs = self.model.predict(X[i], get_outputs=True)
            # Вычисление градиента функции потерь
            loss_gradient = self.model.loss_function.derivative(outputs[-1], y[i])
            # Обратное распространение ошибки для выходного слоя
            # Вычисление градиента
            gradient = self.model.activation_function.derivative(outputs[-1])
            delta = self.model.learning_rate * gradient * loss_gradient
            self.model.weights[-1] -= np.outer(delta, outputs[-2])
            self.model.biases[-1] -= delta
            # Обратное распространение для скрытых слоев с функцией активации ReLU
            for j in range(len(self.model.hidden_layers_sizes) - 1, -1, -1):
                gradient = self.model.activation_function.derivative(outputs[j + 1])
                delta = self.model.learning_rate * gradient * np.dot(self.model.weights[j +
                self.model.weights[j] -= np.outer(delta, outputs[j])
                self.model.biases[j] -= delta
class SGD(Optimizer):
    def __init__(self, model):
        super().__init__(model)
        self.batch\_size = 50
    def mean_from_batch(self, batch_outputs, function):
        return np.mean([
                    function(batch_outputs[j], j)
                    for j in range(self.batch_size)
                ], axis=0)
    def fit(self, X, y):
        indexes = np.arange(X.shape[0])
        np.random.shuffle(indexes)
        X = X[indexes]
        y = y[indexes]
```

```
for i in range(0, X.shape[0], self.batch_size):
            batch_outputs = np.array([
                self.model.predict(X[j], get_outputs=True)
                for j in range(i, i + self.batch_size)
            ], dtype=object)
            loss_gradient = self.mean_from_batch(batch_outputs,
                lambda outputs, j: self.model.loss_function.derivative(outputs[-1], y[i + j]
            )
            gradient = self.mean_from_batch(batch_outputs,
                lambda outputs, _: self.model.activation_function.derivative(outputs[-1]))
            delta = self.model.learning_rate * gradient * loss_gradient
            self.model.weights[-1] -= self.mean_from_batch(batch_outputs,
                lambda outputs, _: np.outer(delta, outputs[-2]))
            self.model.biases[-1] -= delta
            for j in range(len(self.model.hidden_layers_sizes) - 1, -1, -1):
                gradient = self.mean_from_batch(batch_outputs,
                    lambda outputs, _: self.model.activation_function.derivative(outputs[j +
                delta = self.model.learning_rate * gradient * np.dot(self.model.weights[j +
                self.model.weights[j] -= self.mean_from_batch(batch_outputs,
                    lambda outputs, _: np.outer(delta, outputs[j]))
                self.model.biases[j] -= delta
class NAG(Optimizer):
   def __init__(self, model):
        super().__init__(model)
        self.momentums_weights = [np.zeros(weights.shape) for weights in self.model.weights]
        self.momentums_biases = [np.zeros(biases.shape) for biases in self.model.biases]
    def fit(self, X, y):
        for i in range(X.shape[0]):
            for j in range(len(self.model.weights)):
                self.model.weights[j] -= self.momentums_weights[j]
                self.model.biases[j] -= self.momentums_biases[j]
            outputs = self.model.predict(X[i], get_outputs=True)
            loss_gradient = self.model.loss_function.derivative(outputs[-1], y[i])
            gradient = self.model.activation_function.derivative(outputs[-1])
            delta = self.model.learning_rate * gradient * loss_gradient
```

```
delta_weights = np.outer(delta, outputs[-2])
            self.momentums_weights[-1] += delta_weights
            self.model.weights[-1] -= delta_weights
            self.momentums_biases[-1] += delta
            self.model.biases[-1] -= delta
            for j in range(len(self.model.hidden_layers_sizes) - 1, -1, -1):
                gradient = self.model.activation_function.derivative(outputs[j + 1])
                delta = self.model.learning_rate * gradient * np.dot(self.model.weights[j +
                delta_weights = np.outer(delta, outputs[j])
                self.momentums_weights[j] += delta_weights
                self.model.weights[j] -= self.momentums_weights[j]
                self.momentums_biases[j] += delta
                self.model.biases[j] -= delta
class Adagrad(Optimizer):
    def __init__(self, model):
        super().__init__(model)
        self.sum_grads_weights = [np.zeros(weights.shape) for weights in self.model.weights]
        self.sum_grads_biases = [np.zeros(biases.shape) for biases in self.model.biases]
        self.eps = 1e-8
    def fit(self, X, y):
        for i in range(X.shape[0]):
            outputs = self.model.predict(X[i], get_outputs=True)
            loss_gradient = self.model.loss_function.derivative(outputs[-1], y[i])
            gradient = self.model.activation_function.derivative(outputs[-1])
            delta = gradient * loss_gradient
            delta_weights = np.outer(delta, outputs[-2])
            self.sum_grads_weights[-1] += delta_weights ** 2
            self.model.weights[-1] -= self.model.learning_rate * delta_weights * (self.sum_g
            self.sum\_grads\_biases[-1] += delta ** 2
            self.model.biases[-1] -= self.model.learning_rate * delta * (self.sum_grads_bias
            for j in range(len(self.model.hidden_layers_sizes) - 1, -1, -1):
                gradient = self.model.activation_function.derivative(outputs[j + 1])
```

```
delta = gradient * np.dot(self.model.weights[j + 1].T, delta)
                                                    delta_weights = np.outer(delta, outputs[j])
                                                    self.sum_grads_weights[j] += delta_weights ** 2
                                                    self.model.weights[j] -= self.model.learning_rate * delta_weights * (self.su
                                                    self.sum_grads_biases[j] += delta ** 2
                                                    self.model.biases[j] -= self.model.learning_rate * delta * (self.sum_grads_b
class Adam(Optimizer):
             def __init__(self, model):
                           super().__init__(model)
                           self.momentums_weights = [np.zeros(weights.shape) for weights in self.model.weights]
                           self.momentums_biases = [np.zeros(biases.shape) for biases in self.model.biases]
                           self.sum_grads_weights = [np.zeros(weights.shape) for weights in self.model.weights]
                           self.sum_grads_biases = [np.zeros(biases.shape) for biases in self.model.biases]
                           self.beta1 = 0.9
                          self.beta2 = 0.99
                          self.eps = 1e-8
             def fit(self, X, y):
                           for i in range(X.shape[0]):
                                       outputs = self.model.predict(X[i], get_outputs=True)
                                       loss_gradient = self.model.loss_function.derivative(outputs[-1], y[i])
                                       gradient = self.model.activation_function.derivative(outputs[-1])
                                       delta = gradient * loss_gradient
                                       delta_weights = np.outer(delta, outputs[-2])
                                       self.momentums_weights[-1] = self.beta1 * self.momentums_weights[-1] + (1 - self
                                       self.sum\_grads\_weights[-1] = self.beta2 * self.sum\_grads\_weights[-1] + (1 - self.sum\_grads\_weights[-1] + (
                                       self.model.weights[-1] -= self.model.learning_rate * (self.sum_grads_weights[-1]
                                       self.momentums_biases[-1] = self.beta1 * self.momentums_biases[-1] + (1 - self.b
                                       self.sum\_grads\_biases[-1] = self.beta2 * self.sum\_grads\_biases[-1] + (1 - self.sum\_grads\_biase
                                       self.model.biases[-1] -= self.model.learning_rate * (self.sum_grads_biases[-1] +
                                       for j in range(len(self.model.hidden_layers_sizes) - 1, -1, -1):
                                                    gradient = self.model.activation_function.derivative(outputs[j + 1])
                                                    delta = gradient * np.dot(self.model.weights[j + 1].T, delta)
                                                    delta_weights = np.outer(delta, outputs[j])
```

```
self.momentums_weights[j] = self.beta1 * self.momentums_weights[j] + (1 - se
                self.sum_grads_weights[j] = self.beta2 * self.sum_grads_weights[j] + (1 - se
                self.model.weights[j] -= self.model.learning_rate * (self.sum_grads_weights[
                self.momentums_biases[j] = self.beta1 * self.momentums_biases[j] + (1 - self
                self.sum_grads_biases[j] = self.beta2 * self.sum_grads_biases[j] + (1 - self
                self.model.biases[j] -= self.model.learning_rate * (self.sum_grads_biases[j]
import copy
import numpy as np
import matplotlib.pyplot as plt
from dataclasses import dataclass
from typing import Callable, List
@dataclass
class Function:
    func: Callable[[float], float]
    derivative: Callable[[float], float]
class Perceptron:
    def __init__(
        self,
        input_layer_size: int,
        hidden_layers_sizes: tuple,
        output_layer_size: int,
        init_weights_function: Callable[[tuple], tuple],
        loss_function: Function,
        optimizer: Optimizer,
        epochs: int,
        learning_rate: float = 0.01,
    ):
        self.input_layer_size = input_layer_size
        self.hidden_layers_sizes = hidden_layers_sizes
        self.output_layer_size = output_layer_size
        self.loss_function = loss_function
        self.epochs = epochs
        self.learning_rate = learning_rate
        self.activation\_function = ReLU
        # Инициализация весов и смещений (biases)
        self.weights = []
        self.biases = []
        # Веса между входным слоем и первым скрытым слоем
        self.weights.append (init\_weights\_function ((hidden\_layers\_sizes[0], input\_layer\_size)) \\
```

```
self.biases.append(np.random.randn(hidden_layers_sizes[0]))
   # Веса между скрытыми слоями
   for i in range(1, len(hidden_layers_sizes)):
        self.weights.append(init_weights_function((hidden_layers_sizes[i], hidden_layers
        self.biases.append(np.random.randn(hidden_layers_sizes[i]))
   # Веса между последним скрытым слоем и выходным слоем
    self.weights.append(init_weights_function((output_layer_size, hidden_layers_sizes[-1
    self.biases.append(np.random.randn(output_layer_size))
    self.optimizer = optimizer(self)
def predict(self, X: np.ndarray, get_outputs: bool=False, get_probabilities: bool=False)
   outputs = [X]
   # Прямой проход через скрытые слои с функцией активации ReLU
   for i in range(len(self.hidden_layers_sizes)):
        z = np.dot(self.weights[i], outputs[-1]) + self.biases[i]
        outputs.append(np.maximum(0, z))
   # Прямой проход через выходной слой с функцией активации Softmax
    z = np.dot(self.weights[-1], outputs[-1]) + self.biases[-1]
   outputs.append(np.exp(z) / np.sum(np.exp(z)))
   if get_outputs:
        return outputs
   if get_probabilities:
        return outputs[-1]
    return int(np.argmax(outputs[-1]))
def fit(self, X: np.ndarray, y: np.ndarray) -> None:
   y_one_hot = np.zeros((len(y), self.output_layer_size))
    for i, label in enumerate(y):
        y_{one}[i, label] = 1
    for epoch in range(self.epochs):
        self.optimizer.fit(X, y_one_hot)
def evaluate(self, X: np.ndarray, y: np.ndarray) -> float:
   correct\_predictions = 0
    for i in range(len(X)):
        prediction = self.predict(X[i])
        if prediction == y[i]:
            correct_predictions += 1
```

```
# Возвращаем долю правильных предсказаний
        return correct_predictions / len(X)
    def validate(self, X_val: np.ndarray, y_val: np.ndarray) -> float:
        total\_loss = 0.0
        n = len(X_val)
        # Преобразуем метки в one-hot encoding, если это необходимо
        y_one_hot = np.zeros((len(y_val), self.output_layer_size))
        for i, label in enumerate(y_val):
            y_one_hot[i, label] = 1
        for i in range(n):
            # Прямой проход для получения предсказания
            prediction = self.predict(X_val[i], get_probabilities=True)
            # Вычисляем функцию потерь для текущего примера
            loss = self.loss_function.func(prediction, y_one_hot[i])
            total_loss += loss
        # Возвращаем среднее значение функции потерь
        return total_loss / n
def he_init(size):
    return np.random.randn(*size) * np.sqrt(2.0 / size[1])
k = 3
ReLU = Function(
    func=lambda x: np.where(x > 0, k * x, 0),
    derivative=lambda x: np.where(x > 0, k, 0),
MSE = Function(
   func=lambda y_pred, y_true: np.mean((y_true - y_pred) ** 2),
    derivative=lambda y_pred, y_true: 2 * (y_pred - y_true) / y_true.size,
from tensorflow.keras.datasets import mnist
(x_train, y_train), (x_test, y_test) = mnist.load_data()
x_{train} = x_{train.reshape(-1, 28**2) / 255}
x_{test} = x_{test.reshape(-1, 28**2) / 255}
x_train.shape, y_train.shape, x_test.shape, y_test.shape
```

)

)

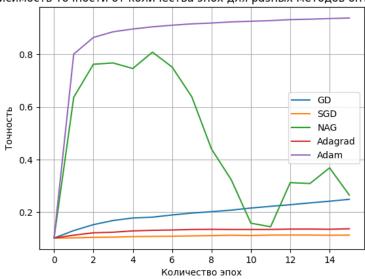
```
def get_accuracies(optimizer):
    model = copy.deepcopy(model_default)
    model.optimizer = optimizer(model)
    accuracies = np.array([model.evaluate(x_test, y_test)])
    losses = np.array([model.validate(x_test, y_test)])
    print(accuracies[-1], losses[-1])
    for i in range(1, epochs_count + 1):
        model.fit(x_train, y_train)
        accuracies = np.append(accuracies, model.evaluate(x_test, y_test))
        losses = np.append(losses, model.validate(x_test, y_test))
        print(accuracies[-1], losses[-1])
    print()
    return accuracies, losses
model_default = Perceptron(
    input_layer_size=28**2,
    hidden_layers_sizes=(256,)*4,
    output_layer_size=10,
    init_weights_function=he_init,
    loss_function=MSE,
    optimizer=GD,
    epochs=1,
    learning_rate=1e-6,
)
epochs_count = 15
epoch_list = list(range(0, epochs_count + 1))
results_GD = get_accuracies(GD)
results_SGD = get_accuracies(SGD)
results_NAG = get_accuracies(NAG)
results_Adagrad = get_accuracies(Adagrad)
results_Adam = get_accuracies(Adam)
plt.plot(epoch_list, results_GD[0], label="GD")
plt.plot(epoch_list, results_SGD[0], label="SGD")
plt.plot(epoch_list, results_NAG[0], label="NAG")
plt.plot(epoch_list, results_Adagrad[0], label="Adagrad")
plt.plot(epoch_list, results_Adam[0], label="Adam")
plt.title("Зависимость точности от количества эпох для разных методов оптимизации")
plt.xlabel("Количество эпох")
plt.ylabel("Точность")
```

```
plt.grid(True)
plt.legend()
plt.show()
def calculate_fitness(person):
   model = Perceptron(
        input_layer_size=28**2,
        hidden_layers_sizes=person,
        output_layer_size=10,
        init_weights_function=he_init,
        loss_function=MSE,
        optimizer=NAG,
        epochs=5,
        learning_rate=1e-6,
    model.fit(x_train[:100], y_train[:100])
    return person, model.evaluate(x_test, y_test)
population = []
М_р = 50 # начальное количество популяций
P_c = 0.4 # доля родителей
P_m = 0.1 # доля мутация
results = []
for layers_count in (np.random.rand(M_p) * 10).astype(int) + 1:
    population.append(calculate_fitness(
        (np.random.rand(layers_count) * 1000).astype(int) + 1
    ))
results.append(np.mean([fitness for _, fitness in population]))
while results[-1] < .3:</pre>
    new_population = []
    np.random.shuffle(population)
    # скрещивание
    for i, (pers1, fit1) in enumerate(population):
        for pers2, fit2 in population[i + 1:]:
            if np.random.rand() > (P_c * fit1 * fit2) ** .3:
                continue
            c = np.random.rand()
            new_population.append(calculate_fitness(
                    *pers1[:int(c * len(pers1))],
                    *pers2[-int((1 - c) * len(pers2)):]
            ))
```

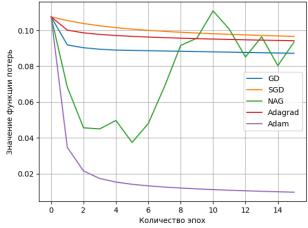
```
# мутации
    while len(new_population) < M_p:</pre>
        for pers, fit in population:
            if np.random.rand() > (P_m * fit) ** .5:
                continue
            pers = [
                int(np.random.rand() * 1000) + 1
                    if np.random.rand() < 1/len(pers)</pre>
                    else layer
                for layer in pers
            if np.random.rand() < 1/len(pers):</pre>
                pers.pop(int(np.random.rand() * len(pers)))
            if np.random.rand() < 1/len(pers):</pre>
                pers.insert(
                    int(np.random.rand() * (len(pers) + 1)),
                    int(np.random.rand() * 1000) + 1
                )
            new_population.append(calculate_fitness(pers))
    population = new_population
    results.append(np.mean([fitness for _, fitness in population]))
plt.plot(*zip(*enumerate(results)), label="Популяция")
plt.title("График изменения качества популяции от итерации")
plt.xlabel("Номер итерации")
plt.ylabel("Качество популяции")
plt.grid(True)
plt.legend()
plt.show()
```

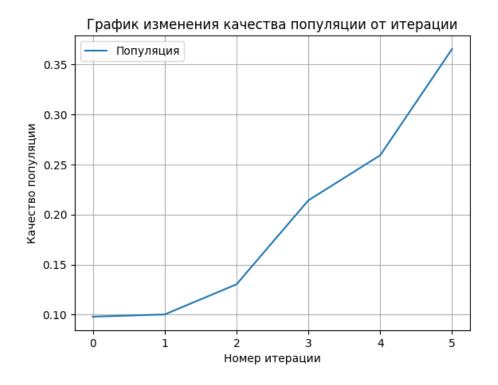
# Результаты

Зависимость точности от количества эпох для разных методов оптимизации



Зависимость значения функции потерь от количества эпох для разных методов оптимизации





## Вывод

- 1. В результате сравнения современных методов оптимизации на примере задачи многослойного персептрона было выявлено, что метод Adam является наиболее эффективным, однако для обучения одной эпохи модели требуется на 20% больше времени в сравнении с прочими методами оптимизации, также метод NAG показывает хорошие результаты, однако после пятой эпохи появляется переобучение. Прочие методы оптимизации не показали своей эффективности в рамках решения задачи многослойного персептрона.
- 2. Был реализован генетический алгоритм для поиска оптимального количества слоев и нейронов в каждом из них. В результате запуска алгоритма с требованием достижения точности в 30% на пятой эпохе было выявлено, что оптимальной конфигурацией скрытых слоев персептрона является следующая: (689, 340, 426, 294, 138, 45).